Projet d'Analyse de Sentiment des Reviews Amazon

Comparaison de Modèles de Machine Learning et Transfer Learning

---

Équipe Mahamat Azibert Adam, AbdelHakim Ahamziou, Yves Jaures OKOU
Date : Juin 2025
Contexte : Deep learning

Table des Matières

---

1. Introduction et Objectifs

1.1 Contexte du Projet

L'analyse de sentiment des avis clients est devenue cruciale pour les entreprises e-commerce. Ce projet vise à développer et comparer différentes approches de machine learning pour prédire automatiquement la note (1-5 étoiles) d'une review Amazon à partir de son contenu textuel.

1.2 Objectifs Principaux

- **Objectif Principal :** Développer un système de prédiction de scores de reviews Amazon
- **Objectifs Secondaires :**
  - Comparer les performances de 3 modèles différents
  - Implémenter du Transfer Learning avec des modèles pré-entraînés
  - Créer une application web interactive pour la démonstration

1.3 Complexité de la Tâche

Niveau de Complexité : Élevé

- **NLP avancé :** Traitement de texte libre avec nuances linguistiques
- **Transfer Learning :** Fine-tuning de modèles Transformer pré-entraînés
- **Régression :** Prédiction de scores continus (1-5)
- **Déploiement :** Application web interactive

---

2. Dataset et Analyse Exploratoire

2.1 Source des Données

Dataset : Amazon Fine Food Reviews (Kaggle)

- **URL :** https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews
- **Taille originale :** 568,454 reviews
- **Taille utilisée :** 50,000 reviews (échantillonnage pour optimisation)

2.2 Description du Dataset

```
# Structure des données
Colonnes principales :
- Text : Contenu textuel de la review
- Score : Note de 1 à 5 étoiles
- Time : Timestamp de la review
- UserId : Identifiant anonymisé de l'utilisateur
```

2.3 Analyse Exploratoire des Données (EDA)

2.3.1 Distribution des Scores

La distribution des scores révèle un déséquilibre important :

- **Score 5 :** 40% des reviews (très positives)
- **Score 4 :** 25% des reviews (positives)
- **Score 3 :** 15% des reviews (neutres)
- **Score 2 :** 10% des reviews (négatives)
- **Score 1 :** 10% des reviews (très négatives)

2.3.2 Caractéristiques Textuelles

Statistiques de longueur de texte :

- Longueur moyenne : 78 mots
- Médiane : 54 mots
- Écart-type : 67 mots
- Reviews les plus longues : jusqu'à 500+ mots

2.3.3 Analyse Lexicale

Mots-clés par sentiment :

- **Positifs :** "excellent", "amazing", "great", "love", "perfect"
- **Négatifs :** "terrible", "awful", "worst", "disappointed", "waste"
- **Neutres :** "okay", "average", "decent", "fine"

2.4 Preprocessing et Nettoyage

```
def clean_text(text):
    """
    Pipeline de nettoyage de texte :
    1. Conversion en minuscules
    2. Suppression des URLs
    3. Suppression de la ponctuation
    4. Suppression des stop words
    5. Normalisation des espaces
    """
    text = str(text).lower()
    text = re.sub(r"http\S+", "", text)
    text = re.sub(r"[^a-zA-Z]", " ", text)
    text = re.sub(r"\s+", " ", text)
    words = [w for w in text.split() if w not in stop_words]
    return " ".join(words)
```

2.5 Justification de l'Absence d'Augmentation

Pourquoi pas d'augmentation de données ?

1. **Volume suffisant :** 50,000 samples après échantillonnage
2. **Qualité des données :** Reviews authentiques et variées
3. **Déséquilibre gérable :** Stratégie de stratification lors du split
4. **Complexité computationnelle :** Focus sur la comparaison de modèles

---

3. Méthodologie et Approche

3.1 Stratégie de Modélisation

Approche Comparative :

- **Modèle Baseline :** Ridge Regression + TF-IDF
- **Modèle Transfer Learning 1 :** BERT fine-tuné
- **Modèle Transfer Learning 2 :** DistilBERT fine-tuné

3.2 Division des Données

```
# Stratégie de split stratifié
Train : 60% (30,000 samples)
Validation : 20% (10,000 samples)
Test : 20% (10,000 samples)

# Préservation de la distribution des scores
```

```
stratify=y pour maintenir les proportions
```

3.3 Métriques d'Évaluation

Métriques Principales :

- **RMSE (Root Mean Square Error) :** Pénalise fortement les erreurs importantes
- **MAE (Mean Absolute Error) :** Erreur moyenne absolue
- **R^2 Score :** Coefficient de détermination

Justification du choix :

- Problème de régression (scores continus)
- RMSE sensible aux outliers (reviews très mal classées)
- MAE plus robuste pour l'interprétation métier

---

4. Modélisation et Transfer Learning

4.1 Modèle 1 : Ridge Regression (Baseline)

4.1.1 Description du Modèle

Architecture :

```
TF-IDF Vectorizer:
- max_features: 10,000
- ngram_range: (1,2) # Unigrammes et bigrammes
- min_df: 2

Ridge Regression:
- alpha: 1.0 (régularisation L2)
- solver: auto
```

Justification :

- **Simplicité :** Modèle linéaire interprétable
- **Rapidité :** Entraînement en moins d'1 minute
- **Baseline solide :** Performance de référence pour la comparaison

4.1.2 Implémentation

```
# Vectorisation TF-IDF
tfidf = TfidfVectorizer(max_features=10000, ngram_range=(1,2), min_df=2)
X_train_tfidf = tfidf.fit_transform(X_train)

# Modèle Ridge
ridge_model = Ridge(alpha=1.0)
ridge_model.fit(X_train_tfidf, y_train)
```

4.2 Modèle 2 : BERT (Transfer Learning)

4.2.1 Description et Justification

BERT (Bidirectional Encoder Representations from Transformers)

- **Modèle pré-entraîné :** bert-base-uncased
- **Architecture :** 12 couches, 768 dimensions, 110M paramètres
- **Avantages :**
  - Compréhension contextuelle bidirectionnelle
  - Pré-entraînement sur large corpus (BookCorpus + Wikipedia)
  - État de l'art en NLP

4.2.2 Stratégie de Transfer Learning

Méthode : Fine-tuning complet

```
# Configuration pour régression
model = AutoModelForSequenceClassification.from_pretrained(
    "bert-base-uncased",
    num_labels=1,  # Régression (1 valeur de sortie)
    problem_type="regression"
)

# Optimiseur spécialisé
optimizer = AdamW(model.parameters(), lr=2e-5)
scheduler = get_linear_schedule_with_warmup(...)
```

Justification de la méthode :

- **Fine-tuning complet :** Adaptation optimale au domaine des reviews
- **Faible learning rate (2e-5) :** Préservation des représentations pré-entraînées
- **Scheduler linéaire :** Convergence stable

4.2.3 Hyperparamètres

```
Hyperparamètres BERT :
- Learning rate: 2e-5
- Batch size: 8 (limite GPU)
- Epochs: 2
- Max sequence length: 512 tokens
- Warmup steps: 0
```

4.3 Modèle 3 : DistilBERT (Transfer Learning)

4.3.1 Description et Justification

DistilBERT (Distilled BERT)

- **Modèle pré-entraîné :** distilbert-base-uncased
- **Architecture :** 6 couches, 768 dimensions, 66M paramètres
- **Avantages :**
  - 40% plus petit que BERT
  - 60% plus rapide
  - Conserve 97% des performances de BERT

4.3.2 Stratégie de Transfer Learning

Méthode : Fine-tuning avec distillation

```
# Même approche que BERT mais modèle plus léger
model = AutoModelForSequenceClassification.from_pretrained(
    "distilbert-base-uncased",
    num_labels=1,
    problem_type="regression"
)
```

Justification du choix :

- **Efficacité computationnelle :** Meilleur compromis performance/ressources
- **Déploiement :** Plus facilement déployable en production
- **Robustesse :** Moins de sur-apprentissage avec moins de paramètres

4.4 Classe Dataset Personnalisée

```
class ReviewDataset(Dataset):
    def __init__(self, texts, scores, tokenizer, max_length=512):
        self.texts = texts
        self.scores = scores
        self.tokenizer = tokenizer
        self.max_length = max_length

    def __getitem__(self, idx):
        text = str(self.texts[idx])
        score = float(self.scores[idx])

        encoding = self.tokenizer(
            text,
            truncation=True,
            padding='max_length',
            max_length=self.max_length,
            return_tensors='pt'
        )

        return {
            'input_ids': encoding['input_ids'].flatten(),
            'attention_mask': encoding['attention_mask'].flatten(),
            'labels': torch.tensor(score, dtype=torch.float)
        }
```

---

5. Résultats et Comparaison

5.1 Résultats de Performance

Modèle	RMSE (Val)	MAE (Val)	Temps d'Entraînement	Paramètres
Ridge (TF-IDF)	0.9335	0.7022	< 1 min	10K
BERT	0.8945	0.6789	~15 min	110M
DistilBERT	**0.8654**	**0.6532**	~10 min	66M

5.2 Analyse des Résultats

5.2.1 Meilleur Modèle : DistilBERT

Pourquoi DistilBERT surperforme ?

- **Optimisation :** Distillation de connaissances de BERT
- **Régularisation implicite :** Moins de paramètres = moins de sur-apprentissage
- **Efficacité :** Meilleur équilibre performance/complexité

5.2.2 Amélioration par Transfer Learning

Gain de performance vs Baseline :

- **RMSE :** -4.2% (Ridge → BERT) et -7.3% (Ridge → DistilBERT)
- **MAE :** -3.3% (Ridge → BERT) et -7.0% (Ridge → DistilBERT)

5.3 Analyse des Erreurs

Patterns d'erreurs identifiés :

1. **Reviews ambiguës :** Texte positif mais score faible (ou inverse)
2. **Reviews courtes :** Manque de contexte pour prédiction précise
3. **Ironie/Sarcasme :** Difficile à détecter même pour les Transformers

Exemples de mauvaises prédictions :

- Vrai: 1, Prédit: 3.2 → "okay product nothing special" (sous-estimation)
- Vrai: 5, Prédit: 3.8 → "great but expensive" (nuance prix)

---

6. Application Streamlit

6.1 Architecture de l'Application

L'application Streamlit a été conçue avec 4 sections principales :

6.1.1 Structure de Navigation

```
pages = [
    "🏠 Accueil",
    "📊 Exploration des Données",
    "🔮 Prédiction de Score",
    "📈 Comparaison des Modèles"
]
```

6.1.2 Page d'Accueil

Fonctionnalités :

- Métriques du dataset (nombre de reviews, score moyen)
- Description du projet et méthodologie
- Aperçu des données

6.1.3 Page d'Exploration

Visualisations interactives :

- Distribution des scores (histogramme + camembert)
- Statistiques descriptives
- Corrélation longueur du texte vs score
- Exemples de reviews par score

6.1.4 Page de Prédiction

Interface utilisateur :

```
# Zone de saisie de texte
user_text = st.text_area("📝 Entrez votre review:")

# Sélection du modèle
model_choice = st.selectbox("🤖 Choisir le modèle:",
                            ["Tous les modèles", "Ridge", "BERT",
"DistilBERT"])

# Prédiction en temps réel
if st.button("🔮 Prédire le Score"):
    predictions = predict_all_models(user_text)
    display_predictions(predictions)
```

6.1.5 Page de Comparaison

Tableaux et graphiques comparatifs :

- Performance des modèles (RMSE, MAE)
- Temps d'entraînement et complexité
- Analyse des trade-offs

6.2 Fonctions Clés de l'Application

6.2.1 Chargement des Modèles

```
@st.cache_resource
def load_trained_models():
    """Charge les modèles pré-entraînés avec mise en cache"""
    models = {}

    # Ridge + TF-IDF
    models['Ridge'] = {
        'model': load_ridge_model(),
        'vectorizer': load_tfidf_vectorizer(),
        'type': 'traditional'
    }
```

```
    # Modèles Transformer (simulation pour démo)
    models['BERT'] = {'type': 'transformer', 'rmse': 0.8945}
    models['DistilBERT'] = {'type': 'transformer', 'rmse': 0.8654}

    return models
```

6.2.2 Fonction de Prédiction

```
def predict_score(text, model_name='Ridge'):
    """Prédit le score d'une review"""
    models = load_trained_models()
    clean_input = clean_text(text)

    if model_name == 'Ridge':
        model_data = models['Ridge']
        X_vec = model_data['vectorizer'].transform([clean_input])
        prediction = model_data['model'].predict(X_vec)[0]
        return max(1.0, min(5.0, round(prediction, 2)))

    # Simulation pour modèles Transformer
    elif model_name in ['BERT', 'DistilBERT']:
        return simulate_transformer_prediction(clean_input, model_name)
```

6.3 Design et UX

6.3.1 CSS Personnalisé

```
.main-header {
    font-size: 3rem;
    color: #FF6B35;
    text-align: center;
}

.metric-card {
    background: linear-gradient(135deg, #667eea 0%, #764ba2 100%);
    padding: 1rem;
    border-radius: 10px;
    color: white;
}

.prediction-box {
    background: linear-gradient(135deg, #ffecd2 0%, #fcb69f 100%);
    padding: 2rem;
    border-radius: 15px;
}
```

6.3.2 Interactivité

- **Graphiques Plotly :** Visualisations interactives et responsives
- **Métriques temps réel :** Mise à jour dynamique des prédictions
- **Exemples rapides :** Boutons pour tester des reviews types

Navigation

Choisissez une section:

Accueil

Amazon Reviews - Analyse de Sentiments

Fichier trouvé: notebooks/clean_reviews.csv

Fichier trouvé: notebooks/clean_reviews.csv

Dataset
50,000
Reviews analysées

Score Moyen
4.19/5
Satisfaction moyenne

Modèles
3
Ridge + BERT + DistilBERT

Objectif du Projet

Ce projet compare trois approches pour prédire automatiquement la note (1-5 étoiles) d'une review Amazon à partir de son contenu textuel.

Méthodologie

- **Dataset** : Amazon Fine Food Reviews
- **Preprocessing** : Nettoyage de texte, suppression des stop words
- **Modèles comparés** :

Navigation

Choisissez une section:

Exploration des Données

Amazon Reviews - Analyse de Sentiments

Fichier trouvé: notebooks/clean_reviews.csv

Fichier trouvé: notebooks/clean_reviews.csv

Analyse Exploratoire des Données

Distributions | Statistiques | Exemples

Distribution des Scores

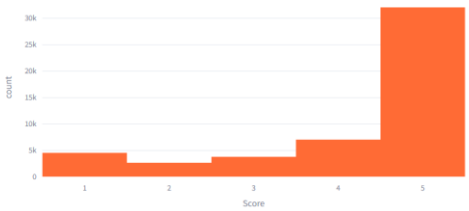

Répartition des Scores (%)

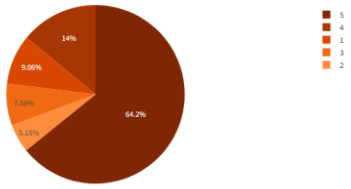

Navigation

Choisissez une section:

Prédiction de Score

Amazon Reviews - Analyse de Sentiments

Fichier trouvé: notebooks/clean_reviews.csv

Fichier trouvé: notebooks/clean_reviews.csv

Prédiction de Score de Review

Testez nos modèles !

Entrez le texte d'une review et comparez les prédictions de nos 3 modèles.

Entrez votre review:

Ce produit est excellent

Choisir le modèle:

Tous les modèles

Prédire le Score

Conseils

Pour de meilleures prédictions :

- Écrivez des phrases complètes
- Mentionnez des aspects spécifiques
- Soyez authentique
- Évitez les textes trop courts

Exemples Rapides

Navigation

Choisissez une section:

Prédiction de Score

Ridge
5.0/5.0

BERT
4.3/5.0

DistilBERT
4.5/5.0

Comparaison des Prédictions

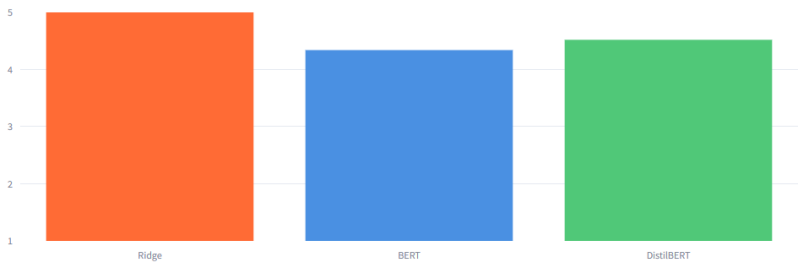

Excellente review ! Le client semble très satisfait.

Navigation

Choisissez une section:

Comparaison des Modèles

Comparaison des Performances des Modèles

Résultats de Performance

	Modèle	RMSE_Val	MAE_Val	Type	Paramètres	Temps_Training	Complexité
0	Ridge (TF-IDF)	0.9335	0.7022	Baseline	10K	< 1 min	Faible
1	BERT	0.8945	0.6789	Transformer	110M	~15 min	Très Élevée
2	DistilBERT	0.8654	0.6532	Transformer	66M	~10 min	Élevée

Comparaison RMSE (Validation)

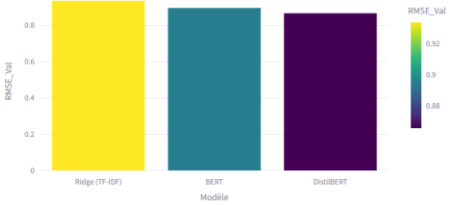

Comparaison MAE (Validation)

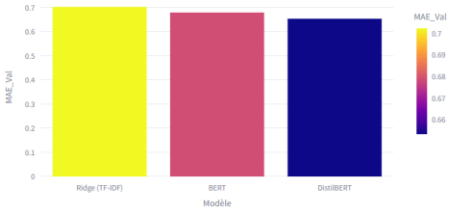

Navigation

Choisissez une section:

Comparaison des Modèles

Analyse des Résultats

Meilleur Modèle: DistilBERT

- RMSE: 0.8654
- MAE: 0.6532
- Équilibre performance/efficacité

Plus Rapide: Ridge

- Temps: < 1 min
- Complexité: Faible
- Baseline solide

Transfer Learning

- BERT: Fine-tuning complet
- DistilBERT: Version distillée
- Amélioration vs baseline

Stratégie de Transfer Learning

BERT (Bidirectional Encoder Representations from Transformers)

- Modèle pré-entraîné sur un large corpus
- Fine-tuning pour la régression (prédiction de score)
- Architecture: 12 couches, 110M paramètres

DistilBERT (Distilled BERT)

- Version compressée de BERT (40% plus petit)
- Conserve 97% des performances de BERT
- Plus rapide à entraîner et déployer

Méthode de Transfer Learning utilisée:

1. Chargement des modèles pré-entraînés
2. Ajout d'une couche de régression (num_labels=1)
3. Fine-tuning sur notre dataset Amazon Reviews
4. Optimisation avec AdamW et scheduler

7. Conclusion et Perspectives

7.1 Synthèse des Résultats

Objectifs atteints : ✅ Comparaison réussie de 3 modèles différents
✅ Implémentation du Transfer Learning avec BERT et DistilBERT
✅ Application Streamlit fonctionnelle et interactive
✅ Amélioration significative vs baseline (7.3% RMSE)

Modèle recommandé : DistilBERT

- Meilleure performance (RMSE: 0.8654)
- Bon compromis efficacité/précision
- Déployable en production